

# Sistema de identificación de frutas en buen estado por medio de redes neuronales convolucionales

IVÁN MICHEL GÓMEZ AZPILCUETA<sup>1,\*</sup> AND GUILLERMO ERNESTO MEDINA MAGDALENO<sup>2,\*</sup>

<sup>1</sup>Facultad de ingeniería, Universidad Autónoma de Querétaro, 2021, Querétaro, México

<sup>2</sup>Facultad de ingeniería, Universidad Autónoma de Querétaro, 2021, Querétaro, México

\*Corresponding author: guillermo.emedina1@gmail.com

\*Corresponding author: email@my-email.com

Compiled October 18, 2021

En el presente trabajo se expone la implementación de un modelo de red neuronal convolucional para la tarea de clasificación de frutas en buen o en mal estado, se muestran los resultados obtenidos y se concluye finalmente con una discusión de resultados y trabajo a futuro.

<http://dx.doi.org/10.1364/ao.XX.XXXXXX>

## 1. INTRODUCCIÓN

La calidad de los productos agrarios en general y de las frutas en particular, es un aspecto que cada día interesa más, no sólo a productores y comerciantes del sector, sino a todo el público ya que, como consumidores que somos, la calidad nos afecta a todos en mayor o menor medida. [1]

El valor agregado en un fruto puede incrementarse con un buen manejo pos cosecha. La clasificación en diferentes parámetros es de las operaciones más importantes. En las pequeñas empresas se realiza de forma manual obteniendo deficiencias en la calidad del producto. Estos problemas se podrían resolver o disminuir con la implementación de algoritmos inteligentes que en este caso incluyen visión artificial y redes neuronales artificiales. [4]

El crecimiento de las Redes Neuronales Artificiales (RNA) o, en inglés, Artificial Neural Network (ANN) ha sido tan importante que, inclusive, han encontrado participación en el campo de los productos alimenticios; tratando de mejorar la calidad de los productos se ha incluido este sistema para realizar labores de inspección de alimentos, teniendo en cuenta las características físicas de estos, y de predicción de cosechas, con el fin de mejorar el estado en que se recogen los alimentos y de distribuirlos en el punto exacto donde se genera más ganancia y el alimento es aprovechable.[3] El buen manejo post cosecha de un fruto siempre es fundamental para asegurar su comercialización. La clasificación de este ayuda a mantener una mejor apariencia y sirve para separarlas en lo que generalmente se comercializa, como cajas, las que pueden contener frutos del mismo tipo y tamaño. Las diferentes necesidades del mercado de frutas hacen que la clasificación de estas sea de suma importancia y las soluciones comunes son hacerlo de manera manual, con personas que se especializan en este trabajo, sin embargo, el rendimiento manual no es suficiente ni rentable. [4]

## 2. MATERIALES Y MÉTODOS

Esta investigación se desarrolló con el lenguaje Python en su versión 3.9, con las librerías de código abierto (OpenCV, Tensorflow y Keras).

### A. Obtención de los datos

Se utilizó un dataset con un total de 13,998 imágenes para la clasificación, el cual se encuentra en la siguiente URL: <https://www.kaggle.com/raghavrpotdar/fresh-and-stale-images-of-fruits-and-vegetables>. La cantidad de imágenes para la red neuronal se divide en las siguientes categorías:

Table 1. Shape Functions for Quadratic Line Elements

Producto	Pasado	Fresco
Manzana	1693 imágenes	2342 imágenes
Pltano	1581 imágenes	1467 imágenes
Pimiento	990 imágenes	901 imágenes
Naranja	1466 imágenes	1595 imágenes
Tomate	981 imágenes	982 imágenes

### B. Estructura de la red utilizada

El primer modelo utilizado se compone de cuatro capas convolucionales con ReLU-activation y max-pooling. Y una capa completamente conectada con ReLU-activation, la prueba se compuso de 50 épocas, con un tamaño de batch de 64. Utilizando únicamente el conjunto de manzanas, en el entrenamiento se utilizaron 2700 imágenes de manzanas frescas y pasadas, y 508 para testing, esto para darnos una idea de cómo funcionaría

nuestro modelo, sin embargo, posterior a esta prueba se pasó a utilizar el dataset completo utilizando el total de las imágenes y categorías mostradas en la tabla (1).



Fig. 1. Ejemplos de imágenes de manzanas frescas.




Fig. 2. Ejemplos de imágenes de manzanas pasadas.

```
model = tf.keras.models.Sequential([
    tf.keras.layers.Conv2D(32, (3,3), activation='relu', input_shape=(150,150,3)),
    tf.keras.layers.MaxPool2D(2,2),

    tf.keras.layers.Conv2D(64, (3,3), activation='relu'),
    tf.keras.layers.MaxPool2D(2,2),

    tf.keras.layers.Conv2D(128, (3,3), activation='relu'),
    tf.keras.layers.MaxPool2D(2,2),

    tf.keras.layers.Conv2D(128, (3,3), activation='relu'),
    tf.keras.layers.MaxPool2D(2,2),

    tf.keras.layers.Dropout(0.5),
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(512, activation='relu'),
    tf.keras.layers.Dense(11)
```

Fig. 3. Arquitectura de la red.

### 3. RESULTADOS

En esta sección se exponen los resultados obtenidos con la red utilizada, para el caso del conjunto de sólo manzanas, se muestra la matriz de confusión y las métricas obtenidas al final del proceso, se puede notar que 260 fueron Manzanas Frescas clasificadas correctamente y 1 como pasada, en comparación 240 manzanas pasadas fueron clasificadas correctamente y una como fresca, con una pérdida de 0.05381, y una eficacia de 99.60 %. Sin embargo, para el caso del dataset completo, se muestran los resultados de la matriz de confusión en la figura (5), se logró una pérdida de 0.12309 y un accuracy de 94.63 % utilizando 100 épocas.




Fig. 4. Matriz de confusión para el conjunto de manzanas.




Fig. 5. Matriz de confusión del dataset completo.

### A. Implementación final

Una vez totalmente entrenada la red, se pondrá a prueba en tiempo real por medio de vídeo, en donde será capaz de diferenciar entre una de las frutas listadas para clasificarlas en frescas o pasadas. Para dicha tarea, se utilizará una tarjeta de Arduino, EL SKETCH "StandardFirmata" y la librería "pyfirmata" de python. El módulo de Arduino será capaz de prender una luz LED en caso de que la fruta en cuestión esté pasada y para el caso contrario no se prendería ninguna luz.

### 4. CONCLUSIONES


A manera de conclusión, se hace hincapié en la capacidad de las redes neuronales convolucionales para la tarea de clasificación de objetos la cual tiene cada vez más impacto e importancia en diversos sectores industriales y civiles de nuestra vida cotidiana, acentuando cada vez más en la integración de la inteligencia artificial en nuestras vidas diarias a pesar de cierto miedo o escepticismo de algunas personas. Para la tarea que compete al presente trabajo, se puede afirmar que los resultados fueron satisfactorios con la arquitectura de la red utilizada, un proyecto a futuro sería la implementación de dicho sistema en un campo agrícola con la capacidad e clasificación en tiempo real para acelerar el proceso de selección de productos en buen estado.

### REFERENCES

1. M. Delhom, La calidad de manzanas y peras. Ministerio de Agricultura, pesca y alimentación. ISBN: 84-341-0496-2 (1985).
2. C. Montoya, J. Cortés, J. Chaves, Sistema automático de reconocimiento de frutas basado en visión por computador. Ingeniare. Revista chilena de ingeniería, vol. 22 N° 4, 2014, pp. 504-516. DOI: <http://dx.doi.org/10.4067/S0718-33052014000400006> (2014).
3. G. Figueredo-Ávila, J. Ballesteros-Ricaurte, Identificación del estado de madurez de las frutas con redes neuronales artificiales, una revisión. Ciencia y Agricultura, vol. 13, núm. 1, pp. 117-132 (2016)

4. C. Mota-Delfin, C. Juárez-González, J. C. Olguín-Rojas, Clasificación de manzanas utilizando visión artificial y redes neuronales artificiales. Ingeniería y Región Vol. 20. DOI: <https://doi.org/10.25054/22161325.1917> (2018).
5. R. Potdar et al, Fresh and Stale Images of Fruits and Vegetables. Disponible en: <https://www.kaggle.com/raghavpotdar/fresh-and-stale-images-of-fruits-and-vegetables/activity> (2021).

## AUTHOR BIOGRAPHIES



**First A. Author**  
(M'76–SM'81–F'87) and the other authors may include biographies at the end of regular papers. This author became a Member (M) of IEEE in 1976, a Senior Member (SM) in 1981, and a Fellow (F) in 1987. The first paragraph may contain a place and/or date of birth (list place, then date). Next, the author's educational

background is listed. The degrees should be listed with type of degree in what field, which institution, city, state, and country, and year degree was earned. The author's major field of study should be lower-cased.

The second paragraph uses the pronoun of the person (he or she) and not the author's last name. It lists military and work experience, including summer and fellowship jobs. Job titles are capitalized. The current job must have a location; previous positions may be listed without one. Information concerning previous publications may be included. Try not to list more than three books or published articles. The format for listing publishers of a book within the biography is: title of book (city, state: publisher name, year) similar to a reference. Current and previous research interests end the paragraph.

The third paragraph begins with the author's title and last name (e.g., Dr. Smith, Prof. Jones, Mr. Kajor, Ms. Hunter). List any memberships in professional societies. Finally, list any awards and work for committees and publications. If a photograph is provided, the biography will be indented around it. The photograph is placed at the top left of the biography. Personal hobbies will be deleted from the biography.



**Alice Smith** received her BSc (Mathematics) in 2000 from The University of Maryland. Her research interests also include lasers and optics.